Tarea 1 - Inferencia 2

Madeline Cecere

Ejercicio 7: Modelo Exponencial-Gamma

En control de calidad se estudia el tiempo de vida útil (en miles de horas) de un componente electrónico. Se asume que el tiempo de vida Y sigue una distribución exponencial con tasa λ, es decir $Y_i \overset{iid}{\sim} Exp(\lambda)$, con densidad $p(y_i|\lambda) = \lambda e^{-\lambda y_i}$. Se observan n componentes, $y = (y_1, \ldots, y_n)$.

1. Muestre que $\lambda \sim Ga(a, b)$ es conjugada para este modelo, y encuentre los parámetros de la posterior.

Aplicando la Regla de Bayes, se tiene que:

$$p(\lambda \mid y) \propto p(y \mid \lambda)\, p(\lambda)$$

Primero calculemos la distribución conjunta para observaciones i.i.d. $y = (y_1, \ldots, y_n)$ de distribución Exponencial con parámetro $\lambda > 0$

$$p(y \mid \lambda) = \prod_{i=1}^{n} p(y_i \mid \lambda) = \prod_{i=1}^{n} \lambda e^{-\lambda y_i} = \lambda^n e^{-\lambda \sum_{i=1}^{n} y_i}$$

Por otro lado, sabemos que $\lambda \sim Ga(a, b)$, es decir $p(\lambda) \propto \lambda^{a-1} e^{-b\lambda}$. Juntando con lo anterior y sustituyendo tenemos que

$$\begin{aligned} p(\lambda \mid y) &\propto \left[\lambda^n e^{-\lambda \sum_{i=1}^{n} y_i}\right] \cdot \left[\lambda^{a-1} e^{-b\lambda}\right] \\ &\propto \lambda^{(a+n)-1} e^{-\lambda\left(b + \sum_{i=1}^{n} y_i\right)} \end{aligned}$$

Que corresponde al núcleo de una distribucion Gamma con parametros $\alpha = a+n$ y $\beta = b+\sum_{i=1}^{n} y_i$, es decir $p(\lambda \mid y) \sim Ga(a+n, b+\sum_{i=1}^{n} y_i)$. Por definición de conjugada, si $p(\theta \mid y)$ pertenece a la misma familia de modelos que la previa, decimos que $p(\theta)$ es conjugada para $p(y \mid \theta)$. En este caso tanta la previa como la posterior pertenecen a la misma familia, por lo que podemos afirmar que $\lambda \sim Ga(a, b)$ es conjugada para este modelo.

2. Interprete los hiperparámetros a y b de la previa como "datos previos": ¿a cuántas observaciones equivale la previa, y qué suma de tiempos representa?

En el enfoque bayaesiano arrancamos con una creencia previa sobre las fallas λ y luego la .ªctualizamos"para obtener la posterior. En nuestro caso probamos n componentes electronicos y medimos su vida util $\sum_{i=1}^{n} y_i$.

De la parte a) tenemos que la posterior es una $Gamma(a+n, b+\sum_{i=1}^{n} y_i)$. El primer parámetro de la posterior es $\alpha = a+n$. Le sumamos a a los n componentes que probe, por ende a se puede interpretar como la cantidad de componentes previos, probados en el pasado. Por otro lado, en el segundo parámetro $\beta = b + \sum_{i=1}^{n} y_i$ a b se le suma la vida útil de los elementos, por lo que modemos interpretar que b refiere al tiempo de vida total previo.

Esta interpretación es coherente con la esperanza de la previa. λ mide cuantas fallas ocurren por tiempo y su esperanza se define como

$$E[\lambda] = \frac{a}{b} = \frac{\text{componentes previos}}{\text{tiempo de vida total previo}} = (\frac{\text{cuantas fallaron}}{\text{cuanto tiempo}})$$

3. Se prueban $n = 10$ componentes y se observa $\sum_{i=1}^{10} y_i = 45$ (miles de horas). Usando una previa $Ga(2, 1)$, calcule la media posterior de λ y de $E[Y] = 1/\lambda$.

Usamos los resultados anteriores de donde la posterior es una $Gamma(a + n, b + \sum_{i=1}^{n} y_i)$ y sustituimos.

$$\alpha = a + n = 2 + 10 = 12$$
$$\beta = b + \sum_{i=1}^{10} y_i = 1 + 45 = 46$$

Entonces en este caso la posterior es $\lambda \mid y \sim \text{Ga}(12, 46)$. De las notas de Inferencia I, sabemos que la esperanza se calcula como

$$E[\lambda \mid y] = \frac{a}{b} = \frac{12}{46} = \frac{6}{23} \approx 0{,}2609$$

Por otro lado, como λ distribuye $Ga(a, b)$, $\frac{1}{\lambda}$ distribuye Gamma Inversa $IG(a, b)$. Ahora, De la observación 1.4.3 de las notas de inferencia se tiene que para $W \sim \text{Ga}(\alpha, \beta)$, si $\alpha + r > 0$ la esperanza de W^{-r} se define como:

$$E[W^r] = \beta^{-r} \frac{\Gamma(\alpha + r)}{\Gamma(\alpha)}$$

En nuestro caso, la gamma inversa, $r = -1$. Entonces para $\alpha > 1$

$$E[W^{-1}] = \beta^{-(-1)} \frac{\Gamma(\alpha - 1)}{\Gamma(\alpha)} = \beta \, \frac{\Gamma(\alpha - 1)}{\Gamma(\alpha)}$$

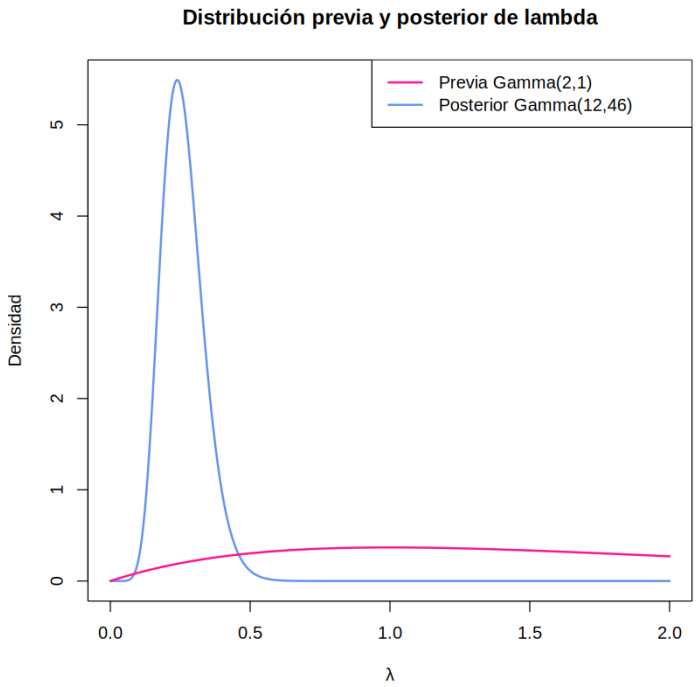
Por propiedad de la función Gamma se tiene que $\Gamma(\alpha) = \Gamma((\alpha - 1) + 1) = (\alpha - 1)\Gamma(\alpha - 1)$, sustituyendo tenemos que

$$E[W^{-1}] = \beta \frac{\Gamma(\alpha-1)}{(\alpha-1)\Gamma(\alpha-1)} = \frac{\beta}{\alpha-1} \quad \text{para } \alpha > 1$$

Volviendo a nuestro caso, $\frac{1}{\lambda} \mid y \sim IG(12, 46)$ y

$$E[E(Y)] = E[\frac{1}{\lambda} \mid y] = \frac{46}{12-1} = \frac{46}{11} \approx 4{,}1818$$

4. Grafique en la computadora la previa y la posterior de λ en la misma figura.



Ejercicio 8 Previa de Jeffreys (3.12 de Hoff)

Jeffreys (1961) sugirió una regla por defecto para generar una distribución previa para un parámetro θ en un modelo de muestreo $p(y \mid \theta)$. La previa de Jeffreys está dada por$p_J(\theta) \propto \sqrt{I(\theta)}$, donde

$$I(\theta) = -\mathbb{E}\left[\frac{\partial^2}{\partial\theta^2} \log p(Y \mid \theta)\right]$$

es la información de Fisher de la muestra.

a) Sea $Y \sim \text{Binomial}(n, \theta)$. Obtener la distribución previa de Jeffreys $p_J(\theta)$ para este modelo.

Primero calculamos la Log-verosimilitud

$$\begin{aligned}\log p(Y \mid \theta) &= \log\left[\binom{n}{Y}\theta^Y(1-\theta)^{n-Y}\right] \\ &= Y\log\theta + (n-Y)\log(1-\theta) + \log\binom{n}{Y}\end{aligned}$$

Luego derivamos respecto de θ dos veces:

$$\frac{\partial}{\partial\theta} = \left(\frac{Y}{\theta} - \frac{n-Y}{1-\theta}\right)$$

$$\frac{\partial^2}{\partial\theta^2} = -\frac{n-Y}{(1-\theta)^2} - \frac{Y}{\theta^2}$$

Luego calculamos la esperanza para obtener la información de Fisher y utilizamos que como $Y \mid \theta \sim \text{Binomial}(n,\theta)$ sabemos que $E[Y \mid \theta] = n\theta$

$$\begin{aligned}I(\theta) &= -E\left[\frac{\partial^2 \log p(Y \mid \theta)}{\partial\theta^2}\middle|\,\theta\right] \\ &= -E\left[-\frac{n-Y}{(1-\theta)^2} - \frac{Y}{\theta^2}\middle|\,\theta\right] \\ &= \frac{n - E[Y \mid \theta]}{(1-\theta)^2} + \frac{E[Y \mid \theta]}{\theta^2} \\ &= \frac{n-n\theta}{(1-\theta)^2} + \frac{n\theta}{\theta^2} \\ &= \frac{n}{1-\theta} + \frac{n}{\theta} \\ &= \frac{n}{\theta(1-\theta)}\end{aligned}$$

Finalmente nos queda que

$$\begin{aligned}p_J(\theta) &\propto \sqrt{\frac{n}{\theta(1-\theta)}} \\ &= \sqrt{n}\,\theta^{-\frac{1}{2}}(1-\theta)^{-\frac{1}{2}} \\ &\propto \theta^{\frac{1}{2}-1}(1-\theta)^{\frac{1}{2}-1}\end{aligned}$$

Por lo tanto, la previa de Jeffreys corresponde a una distribución Beta $\left(\frac{1}{2},\frac{1}{2}\right)$.

b) Reparametrizar el modelo binomial utilizando $\psi = \log\left(\frac{\theta}{1-\theta}\right)$, de modo que

$$p(y \mid \psi) = \binom{n}{y} e^{\psi y}(1+e^{\psi})^{-n}.$$

Obtenga la distribución previa de Jeffreys$p_J(\psi)$ para este modelo.

Primero veamos como se llega a la parametrización!

$$\psi = \log\left(\frac{\theta}{1-\theta}\right) \implies \theta = \frac{e^{\psi}}{1+e^{\psi}} \qquad \text{ver parte c)}$$

y tenemos que la densidad en función de θ es

$$p(y \mid \theta) = \binom{n}{Y}\theta^{Y}(1-\theta)^{n-Y}$$

Sustituyendo nos queda que:

$$\begin{aligned}
p(Y \mid \psi) &= \binom{n}{Y}\left(\frac{e^{\psi}}{1+e^{\psi}}\right)^{Y}\left(1-\frac{e^{\psi}}{1+e^{\psi}}\right)^{n-Y} \\
&= \binom{n}{Y}\left(\frac{e^{\psi}}{1+e^{\psi}}\right)^{Y}\left(\frac{1}{1+e^{\psi}}\right)^{n-Y} \\
&= \binom{n}{Y}\frac{e^{\psi Y}}{(1+e^{\psi})^{Y}(1+e^{\psi})^{n-Y}} \\
&= \binom{n}{Y}\frac{e^{\psi Y}}{(1+e^{\psi})^{Y+n-Y}} = \binom{n}{Y}\frac{e^{\psi Y}}{(1+e^{\psi})^{n}} \\
&= \binom{n}{Y}e^{\psi Y}(1+e^{\psi})^{-n}
\end{aligned}$$

Ahora, a partir de la reparametrización aplicamos nuevamente los pasos anteriores

$$\begin{aligned}
\log p(Y \mid \psi) &= \log\left[\binom{n}{Y}e^{\psi Y}(1+e^{\psi})^{-n}\right] \\
&= Y\psi + \log\binom{n}{Y} - n\log(1+e^{\psi})
\end{aligned}$$

Derivamos

$$\frac{\partial}{\partial\psi} = Y - \frac{ne^{\psi}}{1+e^{\psi}}$$

$$\frac{\partial^2}{\partial\psi^2} = -\frac{ne^{\psi}(1+e^{\psi}) - e^{\psi}ne^{\psi}}{(1+e^{\psi})^2} = -\frac{ne^{\psi}}{(1+e^{\psi})^2}$$

Tomamos la esperanza

$$\begin{aligned}
I(\psi) &= -E\left[\frac{\partial^2 \log p(Y \mid \psi)}{\partial\psi^2}\middle|\psi\right] \\
&= -E\left[-\frac{ne^{\psi}}{(1+e^{\psi})^2}\middle|\psi\right] = \frac{ne^{\psi}}{(1+e^{\psi})^2}
\end{aligned}$$

Entonces la distribución previa de Jeffreys es

$$p_J(\psi) \propto \sqrt{I(\psi)} = \sqrt{n\frac{e^{\psi}}{(1+e^{\psi})^2}} \propto \frac{e^{\psi/2}}{1+e^{\psi}}$$

c) Tome la distribución previa obtenida en el inciso a) y aplique la fórmula de cambio de variable del Ejercicio 3.10 para obtener la densidad previa inducida sobre ψ.

Esta densidad debería ser la misma que la obtenida en el inciso b).Esta consistencia frente a una reparametrización es una característica fundamental de la previa de Jeffreys.

El cambio de variable del ejercicio 3.10 es $\psi = g(\theta)$ donde g es una función monótona en θ, en nuestro caso tenemos que $g(\theta) = \log\left(\frac{\theta}{1-\theta}\right)$ Además se define h como la inversa de g tal que $\theta = h(\psi)$ y se tiene que si $p_\theta(\theta)$ es la densidad de θ entonces la densidad de ψ inducida por θ esta dada por

$$p_\psi(\psi) = p_\theta(h(\psi)) \times \left|\frac{dh}{d\psi}\right|$$

Primero, hay que encontrar $\theta = h(\psi)$:

$$\begin{aligned}
\psi &= \log\left(\frac{\theta}{1-\theta}\right) \\
e^{\psi} &= \frac{\theta}{1-\theta} \\
e^{\psi}(1-\theta) &= \theta \\
e^{\psi} - \theta e^{\psi} &= \theta \\
e^{\psi} &= \theta(1+e^{\psi}) \implies \theta = \frac{e^{\psi}}{1+e^{\psi}}
\end{aligned}$$

Entonces $h(\psi) = \frac{e^{\psi}}{1+e^{\psi}}$. Ahora derivamos:

$$\frac{dh}{d\psi} = \frac{d}{d\psi}\left(\frac{e^{\psi}}{1+e^{\psi}}\right) = \frac{e^{\psi}}{(1+e^{\psi})^2}$$

La distribución previa obtenida en el inciso a) es $p_\theta(\theta) = p_J(\theta) \propto \theta^{\frac{1}{2}-1}(1-\theta)^{\frac{1}{2}-1}$ y por el ejercicio 3.10 tenemos que $p_\psi(\psi) = p_\theta(h(\psi)) \times \left|\frac{dh}{d\psi}\right|$, por lo que sustituimos $h(\psi)$ en la expresión de $p_J(\theta)$:

$$
\begin{aligned}
p_\theta(h(\psi)) &\propto \left(\frac{e^\psi}{1+e^\psi}\right)^{-1/2}\left(1-\frac{e^\psi}{1+e^\psi}\right)^{-1/2} \\
&= \left(\frac{e^\psi}{1+e^\psi}\right)^{-1/2}\left(\frac{1}{1+e^\psi}\right)^{-1/2} \\
&= (e^\psi)^{-1/2}(1+e^\psi)^{1/2}(1+e^\psi)^{1/2} \\
&= e^{-\psi/2}(1+e^\psi)
\end{aligned}
$$

Juntando todo

$$
\begin{aligned}
p_\psi(\psi) &\propto \left[e^{-\psi/2}(1+e^\psi)\right] \times \left[\frac{e^\psi}{(1+e^\psi)^2}\right] \\
&= e^{-\psi/2+\psi}\left(\frac{1+e^\psi}{(1+e^\psi)^2}\right) \\
&= \frac{e^{\psi/2}}{1+e^\psi}
\end{aligned}
$$

Se observa que el resultado es igual a la previa calculada directamente en la parte b)

Ejercicio 10: Modelo normal, inferencia para σ^2
Sea $Y_i \overset{iid}{\sim} N(m, \sigma^2)$, con m un valor conocido. Observamos $y = (y_1, \ldots, y_n)$.

1. Mostrar que $\sigma^2 \sim IG(a, b)$ es conjugada en este modelo, donde

$$
p(\sigma^2) = \frac{b^a}{\Gamma(a)}(\sigma^2)^{-a-1}e^{-b/\sigma^2}
$$

Encuentre los parámetros de la distribución posterior.

Primero, la función de verosimilitud del modelo con los datos observados $y = (y_1, ...y_n)$

$$
\begin{aligned}
p(y \mid \sigma^2) &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i-m)^2}{2\sigma^2}\right) \\
&= (2\pi)^{-n/2}(\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-m)^2\right)
\end{aligned}
$$

Aplicando la regla de Bayes se tiene que la distribucion posterior es proporcional al producto de la previa y la verosimilitud

$$
p(\sigma^2 \mid y) \propto p(y \mid \sigma^2)p(\sigma^2)
$$

Entonces

$$p(\sigma^2 \mid y) \propto \left[(\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - m)^2\right)\right] \cdot \left[(\sigma^2)^{-a-1} \exp\left(\frac{b}{\sigma^2}\right)\right]$$

Ahora agrupando términos

$$p(\sigma^2 \mid y) \propto (\sigma^2)^{-\left(a+\frac{n}{2}\right)-1} \exp\left[\frac{1}{\sigma^2}\left(b + \frac{1}{2}\sum_{i=1}^{n}(y_i - m)^2\right)\right]$$

La posterior tiene exactamente la forma funcional, núcleo, de una distribución Inversa-Gamma. Por lo tanto, la familia Inversa-Gamma es conjugada para este modelo normal con media conocida.

$$\sigma^2 \mid y \sim IG(a_{\text{post}}, b_{\text{post}}),$$

Donde los parámetros son:

$$a_{\text{post}} = a + \frac{n}{2} \qquad b_{\text{post}} = b + \frac{1}{2}\sum_{i=1}^{n}(y_i - m)^2$$

2. Calcule la media, la moda y la varianza de una $IG(a, b)$ en función de a y b. Utilice estas expresiones para describir cómo la media y la moda de la posterior de σ^2 se actualizan respecto de la previa a medida que n crece.

Sea una variable aleatoria $X \sim IG(\alpha, \beta)$ $(a = \alpha, b = \beta)$ veamos sus principales medidas de resumen. Para esto usamos el mismo resultado utilizado en el ejercicio 7. Para $\alpha > 1$

$$E(X) = \beta\frac{\Gamma(\alpha - 1)}{\Gamma(\alpha)} = \beta\frac{\Gamma(\alpha - 1)}{(\alpha - 1)\Gamma(\alpha - 1)} = \frac{\beta}{\alpha - 1}$$

Ahora para calcular $V(X)$ usamos la identidad $V(X) = E(X^2) - E(X)^2$. Con $X^2 = W^{-2}$ y $\alpha > 2$

$$E(X^2) = \beta^2\frac{\Gamma(\alpha - 2)}{\Gamma(\alpha)} = \beta^2\frac{\Gamma(\alpha - 2)}{(\alpha - 1)(\alpha - 2)\Gamma(\alpha - 2)} = \frac{\beta^2}{(\alpha - 1)(\alpha - 2)}$$

Sustituyendo en la identidad

$$\begin{aligned} V(X) &= \frac{\beta^2}{(\alpha - 1)(\alpha - 2)} - \frac{\beta^2}{(\alpha - 1)^2} \\ &= \frac{(\alpha - 1)\beta^2 - (\alpha - 2)\beta^2}{(\alpha - 1)^2(\alpha - 2)} \\ &= \frac{\beta^2}{(\alpha - 1)^2(\alpha - 2)} \end{aligned}$$

Y finalmente, la moda es $E(X) = \frac{\beta}{\alpha+1}$ (según google)

Volviendo a nuestra distribución posterior

$$\sigma^2 \mid y \sim IG(a + \frac{n}{2}, b + \frac{1}{2}\sum_{i=1}^{n}(y_i - m)^2)$$

Media

$$\begin{aligned} E[\sigma^2 \mid y] &= \frac{b + \frac{1}{2}\sum_{i=1}^{n}(y_i - m)^2}{a + \frac{n}{2} - 1} \\ &= \frac{2b + \sum_{i=1}^{n}(y_i - m)^2}{2a + n - 2} \qquad \text{si} \quad a + \frac{n}{2} > 1 \end{aligned}$$

Para analizar el comportamiento cuando $n \to \infty$ podemos descomponer esta expresión en

$$\begin{aligned} E[\sigma^2 \mid y] &= \frac{2b}{2a + n - 2} + \frac{\sum_{i=1}^{n}(y_i - m)^2}{2a + n - 2} \\ &= \frac{2b}{2a + n - 2}\frac{a-1}{a-1} + \frac{\sum_{i=1}^{n}(y_i - m)^2}{2a + n - 2}\frac{n}{n} \\ &= \left(\frac{2a-2}{2a+n-2}\right)\frac{b}{a-1} + \left(\frac{n}{2a+n-2}\right)\frac{\sum_{i=1}^{n}(y_i - m)^2}{n} \end{aligned}$$

Donde $\frac{b}{a-1}$ es la media de la previa. Cuando $n \to \infty$

$$\frac{2a-2}{2a+n-2} \to 0 \qquad \frac{n}{2a+n-2} \to 1$$

Por lo tanto a medida que n crece pierde peso la media de la previa y la media posterior se actualiza convergiendo a la varianza de los datos observador

$$E[\sigma^2 \mid y] \to \frac{\sum_{i=1}^{n}(y_i - m)^2}{n}$$

Moda

$$\begin{aligned} Moda[\sigma^2 \mid y] &= \frac{b + \frac{1}{2}\sum_{i=1}^{n}(y_i - m)^2}{a + \frac{n}{2} + 1} \\ &= \frac{2b + \sum_{i=1}^{n}(y_i - m)^2}{2a + n + 2} \end{aligned}$$

De forma analoga se tiene que

$$Moda[\sigma^2 \mid y] = \left(\frac{2a+2}{2a+n+2}\right)\frac{b}{a+1} + \left(\frac{n}{2a+n+2}\right)\frac{\sum_{i=1}^{n}(y_i - m)^2}{n}$$

Cuando $n \to \infty$ en este caso pierde peso la moda de la previa y se converge igualmente de forma asintótica a la varianza muestral

3. ¿Cuál es la previa de Jeffreys para σ^2? (notar que se deriva respecto de σ^2)

Para una sola observación $Y_i \sim N(m, \sigma^2)$ definiendo $\theta = \sigma^2$, el log de la densidad es:

$$\log p(y_i \mid \theta) = -\frac{1}{2}\log(2\pi) - \frac{1}{2}\log(\theta) - \frac{(y_i - m)^2}{2\theta}$$

Ahora derivamos dos veces respecto de θ

$$\frac{\partial}{\partial\theta}\log p(y_i \mid \theta) = -\frac{1}{2\theta} + \frac{(y_i - m)^2}{2\theta^2}$$

$$\frac{\partial^2}{\partial\theta^2}\log p(y_i \mid \theta) = \frac{1}{2\theta^2} - \frac{(y_i - m)^2}{\theta^3}$$

La información de Fisher para esa observación se obtiene como

$$\begin{aligned} I_{y_i}(\theta) &= -E(\frac{\partial^2}{\partial\theta^2}\log p(y_i \mid \theta)) \\ &= -E(\frac{1}{2\theta^2} - \frac{(y_i - m)^2}{\theta^3}) \\ &= -\frac{1}{2\theta^2} + \frac{E[(Y_i - m)^2]}{\theta^3} \end{aligned}$$

Como $m = E(Y_i)$ por definicion se tiene que $E[(Y_i - m)^2] = \sigma^2 = \theta$. Entonces

$$\begin{aligned} I_{y_i}(\theta) &= -\frac{1}{2\theta^2} + \frac{\theta}{\theta^3} \\ &= \frac{1}{2\theta^2} \end{aligned}$$

Para la muestra $y = (y_1, ..., y_n)$ por iid se tiene que:

$$I_Y(\theta) = nI_{y_1}(\theta)$$

Entonces sustituyendo θ por σ^2

$$p_J(\theta) \propto \sqrt{I_Y(\theta)} = \sqrt{\frac{n}{2\theta^2}} = \sqrt{\frac{n}{2(\sigma^2)^2}} \propto (\sigma^2)^{-1}$$

4. ¿Es Jeffreys el caso límite de la previa conjugada? ¿Para qué valores de a y b?

La previa conjugada es $\sigma^2 \sim IG(a, b)$ donde

$$p(\sigma^2) \propto (\sigma^2)^{-a-1}e^{-b/\sigma^2}$$

Veamos que pasa si hacemos que los hiperparámetros a, b tiendan a cero

Cuando $b \to 0$ se tiene que $e^{-b/\sigma^2} \to 1$

Cuando $a \to 0$ se tiene que $(\sigma^2)^{-a-1} \to (\sigma^2)^{-1}$

Si tomamos ambos límites

$$\lim_{a \to 0, b \to 0} p(\sigma^2) \propto (\sigma^2)^{-1}$$

Y también $p_J(\theta) \propto (\sigma^2)^{-1}$, entonces la previa de Jeffreys es el caso límite de la previa conjugada cuando los hiperparámetros tienden a cero

5. Proponga una opción débilmente informativa para σ^2 (o alguna re-parametrización, por ejemplo sobre $\log \sigma^2$ o σ). Justifique su elección comparando la dispersión que la previa le asigna a σ^2 con la escala de variabilidad que uno esperaría razonablemente en los datos del problema que tenga en mente (es decir, ¿qué tan concentrada o difusa es su previa respecto a los valores plausibles de σ^2?).

Queremos una distribución previa que sea plausible, es decir, no permitir valores teoricamente imposibles como por ejemplo una varianza negativa, pero lo suficientemente flexible o dispersa para que los datos dominen en la forma de la posterior.

Se podria proponer $\sigma^2 \sim IG(1, b)$, esta distribución restringe el soporte de la varianza a valores estrictamente positivos, al tener un parámetro de forma sumamente chico se genera una varianza teórica infinita (no se cumple $a > 2$) por lo que la distribución es extremadamente plana y difusa en el rango de interés. Finalmente, la elección de b puede derivarse de alguna medida de resumen central del problema específico (moda o promedio) de estudios previos. Otro ejemplo visual es la previa del ejercicio 7!